

CEDUS WORKSHOP:

TAG 2

EINFÜHRUNG IN DATA SCIENCE

HEUTIGE AGENDA

- Python: fortgeschrittene Konzepte
- Was ist Data Science?
- die Data-Science-Pipeline
- Case Study: Kickstarter Datensatz

"We are drowning in information but starved for knowledge."

John Naisbitt - Megatrends

MOTIVATION: DATA SCIENCE

- Wir produzieren *riesige* Mengen Daten
 - IBM schätzt 2.5 Quintillionen Byte/Tag
 - Umgerechnet rund 500 Milliarden Bücher, 400 Seiten, DIN A4
- Daten sind größtenteils roh, Wissen muss gefördert werden

[Forbes: How Much Data Do We Create Every Day? The Mind-Blowing Stats Everyone Should Read](#)

DEFINITION: DATA SCIENCE

Data Science (von englisch data „Daten“ und science „Wissenschaft“) bezeichnet generell die Extraktion von Wissen aus Daten.

https://de.wikipedia.org/wiki/Data_Science

- Interdisziplinäres Feld:
Informatik ↔ Statistik ↔ Domänenwissen
- Prozess der aus Daten Wissen generiert
 - Data-Science-Pipeline

DATA SCIENCE - PIPELINE

- **O.S.E.M.N**
 - Obtain Data
 - Scrub / Clean Data
 - Explore Data
 - Model / Visualize Data
 - INterpret our Data

Medium: [A beginner's Guide to the Data Science Pipeline](#)

BEISPIEL: SPIEGELMINING

[Link zum Video](#)

OBTAIN DATA

- (Semi-)automatisiertes Sammeln von Daten
- Oftmals auch: Data Mining
- Herausforderungen/Fragestellungen:
 - Datenformate sollten **maschinenlesbar** sein
 - Woher kommen meine Daten?
 - APIs
 - Crawling
 - Open Data
 - In welcher Qualität sammel ich Daten?

DATENFORMATE

- Legen fest wie Daten formatiert sind
- Aus dem Alltag bekannt: .jpg, .pptx, .gif, .docx
- Maschinenlesbare Datenformate
 - CSV (**C**omma **S**eparated **V**alues)
 - JSON (**J**ava **S**cript **O**bject **N**otation)
 - Markup-Formate (XML, HTML, YAML)

API

- Application **P**rogram Interface
- Schnittstelle, "Datenzapfhahn"
- spezielle URL -> maschinenlesbare Antwort (oft .json)

Beispiel: Wetterdaten openweathermap.org

OPEN DATA

- Datenquellen die offen zur Verfügung stehen
- Open Knowledge Foundation - okfn.de/projekte
- Nachteil: statisch, manuell eingepflegt

Beispiel: open.nrw - Behindertenparkplätze Düsseldorf

CRAWLING

- Alternative wenn weder API noch Open Data verfügbar
- Individuallösung bauen für Daten einer konkreten Quelle bauen
- Nachteil: Hoher Wartungsbedarf; keine Funktionsgarantie
- Webseite ändert Layout
 - Crawler muss umgebaut werden

BEISPIEL: SPIEGELMINING

[Link zum Videoausschnitt](#)

(WEB)CRAWLING-TOOLS FÜR PYTHON

- Crawler lassen sich mit Python umsetzen
- Hilfreiche Bibliotheken:
 - **requests** - Ermöglicht Aufrufen/Zwischenspeichern von URL-Inhalten
 - **BeautifulSoup4** - HTML-Parser, extrahiert Informationen aus Webdokumenten

MINIDEMO: RSS-FEED CRAWLEN

SCRUB / CLEAN DATA

- Daten sind fehlerhaft/unvollständig/schlecht formatiert
- Beispiele:
 - Sensorik misst falsche Werte
(Luftfeuchtigkeit: -4%)
 - Unterschiedliche Formate
05.09.2018 vs. 09/05/2018 vs. 2018/09/05
 - Fehlende Sammelzeitraum (vgl. Spiegelmining)
- Auch: Data Munging / Data Wrangling
- Ziel: Qualität der (Roh-)daten erhöhen!

EXPLORE DATA

- Um Wissen zu extrahieren brauche ich einen Überblick
- Typische Arbeitsschritte:
 - Datendichte reduzieren (Filtern)
 - Überblick durch Visualisierung verschaffen (Plotting)
 - Ausreißer finden
- Durch Exploration ergeben sich Untersuchungspunkte

BEISPIEL: SPIEGELMINING

[Link zum Videoausschnitt](#)

MODEL / VISUALIZE DATA

- Daten müssen modelliert werden
- Typische Aufgaben:
 - Features/Variablen kombinieren
 - Variablen korrelieren
 - Visualisierungsform anpassen
 - Modelle/Algorithmen anwenden (bspw. Clustermodelle)
- Ziel: präzisere Interpretation

BEISPIEL: SPIEGELMINING

[Link zum Videoausschnitt](#)

INTERPRET DATA

- Daten in Wissen übersetzen
- Handlung ableiten
- Kritischster Schritt: Daten können falsch interpretiert werden

Die Seite [spuriouscorrelations](#) lässt dich absurde Statistiken zusammenkorrelieren

BEISPIEL: SPIEGELMINING

[Link zum Videoausschnitt](#)

DATA SCIENCE MIT PYTHON

NÜTZLICHE BIBLIOTHEKEN:

- **pandas** - Daten einlesen, verarbeiten, filtern
- **matplotlib** - Daten visualisieren
- **scipy** - Lineare Algebra / Optimierung
- **scikit-learn** - Bibliothek fürs Machine Learning
- **nltk** - Bibliothek fürs Natural Language Processing

KAGGLE - DATASCIENCE- PLATTFORM

- "Your Home for Data Science"
- Bietet.. :
 - Lernmaterialen
 - Notebooks zum Nachlesen & Nachbauen
 - von der Community zur Verfügung gestellte Datensätze

WALKTHROUGH: KAGGLE

Kaggle - "Your Home for Data Science"

CASE-STUDY: KICKSTARTER- DATENSATZ

FRAGEN? FEEDBACK?